

可解释性说明文档

本作品为规则基线与本地大模型结合的方案，未使用任何训练数据、未训练任何模型，因此不涉及传统“训练过程可解释”，而是聚焦**决策过程可解释**：系统为什么这样理解、为什么这样应答，全部可追踪、可审计。

1 整体设计：可解释的三层结构

语音/视线/手势/手动输入



L1 规则基线（确定性、可审计）

意图识别、对象消歧、页面约束、
执行动作、安全裁决全部在此层完成

仅当规则不足时（冲突解释/个性化润色）



L2 本地大模型（受限、可回退）

只输出解释/润色文本，不能改变执行结果

关键约束：无论大模型输出什么，最终执行的意图、对象与动作都由规则层裁决。因此每个决策都有确定的代码路径，可解释即“可定位到具体规则”。

2 输入侧可解释：多模态如何融合

- 统一事件：**每个模态事件为（模态，时间戳，置信度，载荷），如 语音("给妈妈发消息...", t=120ms, 置信度0.92)、视线(目标=妈妈卡片, t=300ms, 置信度0.85)。
- 对齐窗口：**以语音为锚点，取前后 3 秒内的视线、5 秒内的屏幕上下文做窗口对齐（GAZE_ALIGNMENT_BEFORE_MS=3000）。
- 消歧优先级（可解释规则）：**语音明确说出姓名 > 手动选择 > 视线（置信度 ≥ 0.55 且对象可见）> 历史选择。界面解释条会明确写出“对象来源：语音/手动/视线”，让用户知道系统依据了什么。

3 决策侧可解释：每个场景的规则链

3.1 发消息

- 语音文本经近音纠错与插入语剥离（“让他/叫她/的/一个”）；
- 姓名匹配命中（精确→模糊），否则检查手动选择，否则检查视线；
- 显式否定（“别/不/算了”）优先于视觉确认；
- 低置信度视线不采用，转澄清：“没有听清您要给谁发，请再说一次”；
- 发送前必须用户确认。→ 每步都可回放，界面上“解释条”展示来源。

3.2 音乐播放

1. 页面白名单：音乐相关指令只在音乐相关页面生效，其余忽略；
2. 模式（专注/开车/娱乐）决定候选池：偏好歌单 + 每 3 次插入 1 次大众常听（探索）；
3. 用户明确点名歌曲时优先精确播放，推荐只作用于未点名的情况；
4. 播放器显示推荐理由，如“根据您在专注模式的偏好推荐”，说明个性化依据。

3.3 日程与提醒

1. 时间词解析：今天/明天/后天/具体日期，映射到对应范围查询；
2. 提醒：默认提前 50 分钟（可被用户画像调整），设置后可撤销；
3. “取消组会的提醒”这类否定指令通过标题双向包含匹配 + 剥离语气词解析；
4. 查询结果原位刷新，并标注“提醒已设置”状态，全过程可视化。

4 个性化侧可解释：画像可见、可清除

- 偏好画像（音乐分模式歌单、提醒提前量）来自本地使用历史，**不包含人脸/语音/备忘录原文**，仅存统计特征；
- 界面提供“偏好说明”，用户可查看推荐依据并清除画像；
- 画像只影响推荐排序与提醒默认值，**永不改变用户明确指令的执行结果**。

5 安全与边界（可审计项）

- 原始音频、视频帧、备忘录内容全程本机处理，不上传任何服务；
- 大模型仅用于文本整理与解释，输出经规则层校验后才可展示，且不改变执行；
- 本地大模型 2.8s 超时即回退规则模板，保证单轮应答 <5s；
- 所有否定、取消、撤销操作都有规则级兜底，不依赖模型判断。

6 结论

本方案以“规则基线可审计、大模型只做锦上添花”为原则，实现了**输入可解释（来源可查）、决策可解释（规则可定位）、个性化可解释（依据可见、可清除）**，在端侧离线约束下兼顾安全、性能与自然语言体验。