

多模态个性化终端助手 —— 项目文档

版本 1.0 2026.08.31

1 项目概况

1.1 背景和基础

智能终端交互正从单一文字/语音指令走向语音+视线+手势+环境上下文的组合表达。例如用户一边看向屏幕上的联系人一边说“给他发消息”，系统需要把“他”与注视对象关联起来。端侧部署还要求轻量、实时、隐私闭环（人脸/语音特征不上传）。

团队基于华为赛题五（智能终端多模态输入感知与识别及个性化应答）开发本系统。已有基础：完整的本地演示原型（Python 标准库后端 + 浏览器端 MediaPipe 视觉 + 本地 Whisper 语音识别），覆盖消息、音乐、日程三个场景，并配备 30 条端到端验收样例与 24 条单元/回归测试。

1.2 场景和价值

- 场景：**面向普通 Windows 笔记本/PC 的端侧个人助手，覆盖三类典型交互——注视联系人并发消息、分场景个性化音乐推荐、授权本地备忘录的日程查询与提醒。
- 价值：**以“规则基线 + 轻量本地大模型”的可解释架构解决端侧多模态融合的落地问题；隐私敏感数据（人脸、语音、备忘录）全程本机处理，符合隐私合规趋势；无需第三方账号与云服务，断网可用。

1.3 所需支持

- 硬件：**普通 Windows 笔记本（摄像头、麦克风）；评测机无需 GPU。
- 软件：**Python 3.12+（仅标准库）、现代浏览器（Chrome/Edge，用于 Web Speech 与 MediaPipe）、Ollama（可选，用于本地大模型解释，`qwen2.5:3b-instruct`）。
- 模型资源：**本地 Whisper-tiny 量化模型（约 45MB）、MediaPipe Face/Gesture 模型与 WASM 运行时均随代码包发布。

2 项目规划

2.1 整体目标

交付一个可在普通 Windows 笔记本上离线运行的多模态个性化终端助手原型：三类意图（发消息、音乐播放、日程查询）理解准确、对象消歧可靠、应答个性化可解释，并满足“原始音视频/备忘录不上传、单轮应答 < 5s、断网可用”的约束。以 30 条验收样例全部通过作为可复现的验收基线。

2.2 技术创新点

- 可解释的规则基线 + 受限大模型：**意图、对象与执行由确定性安全规则裁决（显式否定优先、低置信度澄清、必须确认），大模型只做冲突解释与个性化润色，且输出不能改变执行结果——兼顾安

全与自然语言表达；

2. **语音指令的页面级约束与近音纠错**：语音指令按当前页面过滤（日程页说“播放下一首”被忽略），识别文本先经本地大模型整理（纠正近音词、剥离“让他/的/一个”等插入语）再交规则，显著降低误触发；
3. **多模态对象消歧**：语音说出的联系人姓名 > 手动选择 > 视线（含低置信度拦截）> 历史选择，并做屏幕可见性校验；
4. **端侧全离线链路**：浏览器内 Whisper 语音识别 + MediaPipe 视线/手势 + 本地大模型，人脸/音频/备忘录不出设备；
5. **日程提醒的交互闭环**：手动/语音/（曾支持）视线三种设置方式，提醒可撤销，日程视图原位刷新不跳转。

3 实施方案

3.1 技术可行性分析

- **数据**：演示数据（联系人/曲库/备忘录）为项目内置；语音识别使用公开的 Whisper 模型（Xenova 的 ONNX 转换），未使用私有数据；未训练自定义模型，不涉及人工标注（符合“允许 ≤ 500 条标注”的约束，本项目采用零标注的规则+提示词方案）。
- **行业知识**：交互语义（“发消息”“下一首”“明天安排”等）通过规则模式库与语料库建模，可解释、易扩充。
- **算力硬件**：端侧推理为浏览器 MediaPipe/ONNX WASM + 本地 Ollama 3B 模型，普通笔记本即可运行；评测无需 GPU。
- **可行性结论**：技术路线成熟、依赖可控、离线可复现，满足赛题端侧部署约束。

3.2 技术细节

- **多模态对齐**：统一事件格式 `modality + timestamp_ms + confidence + payload`；语音事件为锚点，取前后 3 秒内视线、5 秒内屏幕上下文（`GAZE_ALIGNMENT_BEFORE_MS=3000`），做窗口对齐与对象可见性校验；
- **意图理解**：`parse_simulated_speech` 规则解析（精确匹配→模式→模糊关键词兜底），并按页面白名单过滤；日程支持今天/明天/后天/优先级/压力分析/提醒设置等 12+ 意图；
- **冲突与安全**：显式否定词优先于视觉确认；低置信度视线（ < 0.55 ）不采用并澄清；消息发送必须确认；LLM 输出不改变意图/对象/执行；
- **个性化**：分模式（专注/开车/娱乐）曲目偏好歌单与“每三次穿插大众常听”的探索推荐；页面建议按历史动作映射排序；头部手势幅度自适应阈值；日程提醒按画像提前量（默认 50 分钟）推导；
- **语音识别**：优先浏览器 Web Speech（即开即用），不可用时回退本地 Whisper-tiny 量化模型；识别文本进入可编辑确认框，确认后交由大模型整理、规则执行；
- **性能指标**：本地大模型单轮 2.8s 超时即回退规则模板；浏览器端事件处理为内存操作；实测 30 条验收样例全部通过（见测试结果报告）。

3.3 计划和分工

阶段	内容	时间
1	架构搭建：本地服务 + 三页面原型 + 事件协议	8 月中旬
2	多模态对齐与意图识别（规则基线）	8 月中下旬
3	个性化：音乐偏好、建议面板、提醒链路、手势画像	8 月下旬
4	端侧语音识别（Web Speech + Whisper 回退）与语音整理	8 月下旬
5	验收：30 条样例运行器、单元/回归测试、界面润色	8 月底
6	提交材料：项目文档、视频、可解释性文档、测试报告	8 月底-9 月初

团队分工：成员 A 负责前端交互、视线/手势与语音输入；成员 B 负责后端多模态对齐、意图规则、个性化与测试。

4 参考资料

- 华为赛题五《智能终端多模态输入感知与识别及个性化应答》（2026 年中国研究生人工智能大赛）
- Hugging Face `Xenova/whisper-tiny`（Whisper ONNX 转换，MIT/Apache 许可）
- Google MediaPipe Tasks Vision（Face Landmarker / Gesture Recognizer，Apache 2.0）
- `@huggingface/transformers`（`transformers.js`，Apache 2.0）
- Qwen2.5（通义千问开源模型，Apache 2.0）